

Behavior Score CMV - Pré-Pago → Controle

Pré-processamento · Decisões Técnicas · Modelo Final CatBoost v1.0 · Métricas de Performance

Este documento consolida a entrega completa do Squad 3: uma solução de Credit Scoring comportamental ponta a ponta, construída para viabilizar a expansão sustentável da base Pré-Pago para Controle da Claro.

O ecossistema integra uma arquitetura Medallion sobre infraestrutura Oracle - com DuckDB, Airflow e Terraform - a um modelo CatBoost v1.0 otimizado via busca Bayesiana, governado por critérios ESG estritos e validado sob condições reais de operação.

Cada decisão arquitetural registrada aqui - dos vetos técnicos às escolhas de infraestrutura - foi tomada com um objetivo único: entregar um motor de decisão escalável, auditável e pronto para produção.

Ecossistema Squad 3 - Repositórios

Repositório	Foco	Descrição
 squad3-core	Engine + Medallion + Governança	Define o que a arquitetura executa: processamento, pipeline e gestão de performance com governança de dados nativa.
 squad3-ops	IaC + Orquestração + Cloud Readiness	Define como e onde a arquitetura é executada: infraestrutura como código, orquestração e estratégias OCI.

Painéis Interativos - Streamlit Apps

Painel	Módulos
  Painel de Observabilidade  Demo: Painel em Operação	 Core Engine - Pipeline · Profiling · Quality · Integrity  Compute & Storage (OCI)  FinOps Governance - Custos e Budget
  Painel de Análise e Decisão  Demo: Painel em Operação	 Geral Análise de Dados (EDA)  Performance & Benchmark  Impacto para o Negócio  Estratégia de Política de Crédito  Motor de Decisão (Deploy do Modelo)

Parte 1 - Pré-processamento e Engenharia de Dados

1. Pré-processamento e Engenharia de Dados (Data Lineage)

- [1.1 Visão Global do Fluxo de Dados \(CORE\) - Arquitetura Medallion](#)
- [1.2 Princípios Técnicos Aplicados - Governança e Reprodutibilidade](#)
- [1.3 Camada RAW - Ingestão e Preservação da Fonte](#)
- [1.4 Camada BRONZE - Padronização Técnica](#)
 - [1.4.1 Etapas Comuns de Processamento \(todas as entidades\)](#)
 - [1.4.2 Tratamento Diferenciado - Dimensões Técnicas \(atraso_dim, recarga_dim\)](#)
- [1.5 Camada SILVER - Qualidade, Unicidade e Enriquecimento](#)
 - [1.5.1 Estratégia de Grão e Unicidade por Entidade](#)
 - [1.5.2 Regras de Transformações Específicas](#)
 - [1.5.3 Resultado da Camada SILVER](#)
- [1.6 Camada GOLD - Consolidação de Ativos \(Expansão & Controle\)](#)
 - [1.6.1 Objetivos da Camada GOLD](#)
 - [1.6.2 Ativos GOLD: Estratégia de Expansão e Baseline de Controle](#)
 - [1.6.3 Governança de Histórico e Versionamento \(run_id\)](#)
- [1.7 Estrutura Física de Armazenamento \(Padrão Hive\)](#)

Parte 2 - Estruturação do Modelo de Machine Learning

2. Modelo Final CatBoost v1.0 - Veredito Executivo

- [2.1 Resultados Consolidados - KS, Gini, AUC, PSI, Swap](#)
- [2.2 Três Pilares do Veredito \(ESG · Poder Preditivo Comportamental · Alta Performance\)](#)

3. Decisões Arquiteturais de Modelagem

- [3.1 Restrições Monotônicas - Veto \(Degradação de Performance Confirmada\)](#)
- [3.2 Redução de Dimensionalidade via SHAP - Cortes Agressivos Rejeitados](#)
- [3.3 Ensembling Tradicional - Veto \(Complexidade vs Ganho Marginal\)](#)
- [3.4 A Virada de Chave: LightGBM → CatBoost Puro \(Decisão Final\)](#)

4. Pipeline de Dados e Configuração do Modelo

- [4.1 Carga Otimizada da ABT Gold \(DuckDB - 2.633.900 registros, Bad Rate 21.23%\)](#)
- [4.2 Estratégia de Split - Holdout Controle \(ZZ/ZX\) e Temporal \(OOT\)](#)
- [4.3 Blocos de Features - 62 Variáveis em 5 Domínios de Negócio](#)
- [4.4 Hiperparâmetros do Modelo Final - CatBoost + Optuna \(Best: 2026 árvores\)](#)

5. Estratégia de Treinamento Incremental - Waterfall de KS

- [5.1 Resultados do Waterfall - Evolução Incremental por Bloco](#)
- [5.2 Contribuição por Fonte de Dados - Insight: O Poder da Recarga \(+2.82pp\)](#)

Parte 3 - Métricas de Performance e Validação

6. Resultados e Métricas de Performance

[6.1 Métricas Globais - KS / Gini / AUC \(Train / Test / OOT\)](#)

[6.2 Análise de Decis - Gains Table OOT \(Decil 1: 4.9% → Decil 10: 52.4%\)](#)

[6.3 Feature Importance - CatBoost Native](#)

[6.4 Calibração de Probabilidade - Brier Score e Reliability Diagram](#)

7. Validação de Estabilidade

[7.1 Population Stability Index - PSI Global Score: 0.0009 \(Estável\)](#)

[7.2 PSI por Feature - Data Drift \(todas < 0.10, nenhuma crítica\)](#)

[7.3 Bootstrap 1000x - Intervalos de Confiança do KS \(Compactos e Separados\)](#)

8. Análise de Valor de Negócio - Swap-In / Swap-Out

[8.1 Matriz de Decisão - 4 Segmentos \(Holdout Controle, Cutoff P70\)](#)

[8.2 Impacto Direto na Carteira - Redução de 18.23pp no Volume Rotacionado](#)

9. Plano de Monitoramento em Produção

[9.1 Gatilhos de Alerta e Limiares Críticos](#)

[9.2 Interpretação Financeira dos Limiares](#)

[9.3 Cadência e Responsabilidades](#)

[9.4 Protocolo de Diagnóstico em Caso de Alerta](#)

[9.5 Sinais de Atenção Específicos por Domínio](#)

[9.6 Critério de Desativação do Modelo](#)

Apêndices

[A.1 Data Architecture - Estratégia de Cloud Readiness \(OCI Execution\)](#)

[A.2 Provisionamento IaC \(Terraform\) - Infraestrutura como Código](#)

[A.3 Orquestração de Fluxos \(Airflow\) - DAGs e Estratégia de Agendamento](#)

[A.4 Análise de Impacto Financeiro - Projeção Nacional 12 Meses](#)

1. Pré-processamento e Engenharia de Dados (Data Lineage)

1.1 Visão Global do Fluxo de Dados (CORE)

Todas as entidades seguem o padrão arquitetural Medallion (*RAW* → *BRONZE* → *SILVER* → *GOLD*), com responsabilidades bem definidas por camada.

Esta visão representa o **fluxo lógico comum** do Lakehouse, independentemente de particularidades de implementação ou exceções controladas por tipo de dado.



Camada	Papel no Pipeline
RAW	Persistência do dado original, sem transformação
BRONZE	Padronização técnica e organização física
SILVER	Qualidade, unicidade e enriquecimento
GOLD	Camada semântica para modelagem (ABTs e Labels ML-ready)

Entidades contempladas neste fluxo:

- `atraso`
- `pagamento`
- `recarga`
- `dados_cadastrais`
- `score_bureau_movei`
- `telco`
- dimensões de suporte (`atraso_dim`, `recarga_dim`)

1.2 Princípios Técnicos Aplicados

Para garantir a reprodutibilidade e a confiabilidade, o Lakehouse adota os seguintes princípios em todas as etapas de processamento:

- **Isolamento por Execução (`run_id`):** Todas as transformações são versionadas, permitindo rastreabilidade completa e isolamento de falhas.
- **Particionamento Temporal (`ano_mes`):** Organização física em padrão Hive que habilita o **Partition Pruning**, garantindo que as consultas leiam apenas as pastas necessárias, otimizando drasticamente a performance e o custo de processamento.
- **Grão Analítico Imutável:** Definição rigorosa da unicidade por entidade para evitar duplicação e perda de integridade.
- **Prevenção de Data Leakage:** Governança temporal rigorosa na transição para a camada final via *Point-in-Time Join*.
- **Auditoria Automática:** Validação de integridade e cobertura em cada salto de camada.
- **Persistência de Evidências (Observability):** Centralização de todos os logs técnicos e relatórios de qualidade (`.md` e `.log`) no Data Lake, permitindo que qualquer processamento histórico tenha sua saúde validada retroativamente.

1.3 Camada RAW - Ingestão e Preservação da Fonte

Objetivo:

Garantir a **preservação integral** dos dados recebidos das fontes, sem qualquer modificação estrutural ou semântica.

Características:

- Arquivos no formato original (`parquet` ou `csv`)
- Fonte oficial para reprocessamentos

Estrutura: `s3://lake/raw/{entidade}/*`

1.4 Camada BRONZE - Padronização Técnica

Este estágio é **comum a todas as entidades de negócio** e tem como objetivo a **padronização técnica**, mantendo a imutabilidade dos dados.

1.4.1 Etapas Comuns de Processamento

Entidades: `atraso`, `pagamento`, `recarga`, `dados_cadastrais`, `score_bureau_movei`, `telco`

Origem: `s3://lake/raw/{entidade}/*.parquet`

Destino: `s3://lake/bronze/{entidade}/run_id={run_id}/ano_mes={YYYYMM}/*.parquet`

Etapa	Processo	Descrição
1	Normalization (Lowercase)	Conversão de todos os nomes de colunas para minúsculo, eliminando ambiguidades de <i>case-sensitivity</i> .
2	Tipagem Forte	Aplicação de <code>CAST</code> explícito baseada no profiling da origem.
3	Metadados Técnicos	Inclusão de colunas técnicas (<code>ingestion_ts</code> , <code>run_id</code>) para rastreabilidade e auditoria.
4	Particionamento Técnico	Criação da coluna técnica <code>ano_mes</code> derivada da data de referência principal da entidade.

1.4.2 Tratamento Diferenciado - Dimensões Técnicas

As tabelas dimensionais possuem comportamento distinto das tabelas 'Fato', pois representam **cadastros estáveis e de baixo volume**.

Entidades: `atraso_dim`, `recarga_dim`

Origem: `s3://lake/raw/{dimensao}/*.csv`

Destino: `s3://lake/bronze/{dimensao}/*.parquet`

Regra	Descrição	Justificativa
Estrutura Flat	Arquivo único, sem particionamento por data ou <code>run_id</code> .	Simplifica manutenção e JOINS laterais.
Preservação de Case	Manutenção do formato original das chaves.	Evita falhas de correspondência.
Snapshot Técnico	Representam o estado completo do cadastro.	Dimensões não são versionadas por execução.

1.5 Camada SILVER - Qualidade, Unicidade e Enriquecimento

Na camada Silver, os dados são refinados para atender aos **requisitos de qualidade, unicidade e semântica analítica**, respeitando o grão técnico de cada entidade. A estrutura de particionamento físico por `ano_mes` é herdada da camada Bronze, garantindo a consistência organizacional do Lakehouse.

Origem: `s3://lake/bronze/{entidade}/**/*.parquet`

Destino: `s3://lake/silver/{entidade}/run_id={run_id}/ano_mes={YYYYMM}/*.parquet`

1.5.1 Estratégia de Grão e Unicidade por Entidade

Entidade	Grão Técnico (Unicidade)
Atraso	num_cpf, contrato, dat_referencia, num_fatura_hash, num_ent_seq_fatura
Recarga	num_cpf, dw_num_ntc, dat_insercao_credito, hor_insercao_credito
Pagamento	num_cpf, contrato, seq_fatura, num_sub_seq_fatura, num_credito_seq
Dados Cadastrais	num_cpf, safra, prod
Score Bureau	num_cpf, safra, prod
Telco	num_cpf, safra, prod

💡 Nota de Arquitetura e Governança de Dados

- Exceção Estratégica: Pagamento

Diferente das datas de referência de outras tabelas, a `dat_status_fatura` não foi incluída no grão de unicidade.

- **Motivo:** Nesta entidade, a data reflete apenas a mudança de estado (ex: aberta para paga) de um registro já existente. Incluí-la causaria a duplicidade do mesmo fato financeiro.
- **Impacto:** Esta lógica evitou que **8.163 registros obsoletos** inflassem o somatório de receita, garantindo a **última verdade** de cada lançamento.

- Precisão Temporal e Identificação de Linha: Recarga

A combinação da alta granularidade temporal (`hor_insercao_credito`) com o identificador da linha (`dw_num_ntc`) é o que garante a integridade desta entidade.

- **Detalhe Técnico:** O valor da hora representa os segundos decorridos desde a meia-noite (Padrão SAS/Legacy) e é processado como **BIGINT**, permitindo distinguir transações simultâneas em linhas distintas de um mesmo titular.
- **Impacto:** Esta estratégia permitiu identificar e remover **4.766.668 registros redundantes**, provenientes de possíveis falhas de **double ingestion** na origem, corrigindo um possível desvio de **4.7%** no faturamento total reportado.

1.5.2 Regras de Transformações Específicas

Apesar do fluxo base ser comum, algumas entidades possuem **processamentos adicionais**.

a) Enriquecimento via Dimensões *(Aplicável a Atraso e Recarga)*

- JOIN com tabelas dimensionais técnicas.
- Inclusão de descrições legíveis ao negócio.
- Mapeamento de códigos inexistentes para valores padrão (ex: "Não Mapeado").
- Preservação do grão original da 'Fato' (entidades de domínio com comportamento factual).

b) Saneamento e Higienização *(Todas as Entidades)*

- Normalização de hashes técnicos associados a valores nulos.
- Padronização de identificadores inválidos.
- Remoção de colunas sem valor analítico (100% nulas ou obsoletas).
- Reordenação lógica do schema para consumo analítico.

1.5.3 Resultado da Camada SILVER

Ao final do processamento na camada Silver, todas as entidades apresentam:

- Grão técnico garantido
- Unicidade validada
- Chaves normalizadas
- Schema otimizado
- Dados prontos para análises exploratórias, agregações controladas e estruturação de ativos na camada GOLD.

[🔗 Dicionário de Dados - Camada Silver](#)

1.6 Camada GOLD - Consolidação de Ativos (Expansão & Controle)

A camada **GOLD** materializa os dados para Machine Learning através de ativos semânticos, versionados e auditáveis. Para garantir a **cobertura total do ecossistema** e, simultaneamente, atender às **necessidades de especialização** do projeto, a camada foi estruturada em dois conjuntos de ativos complementares: um focado na **amplitude de público (Expansão)** e outro voltado à **densidade transacional (Controle)**.

1.6.1 Objetivos da Camada GOLD


- **Especialização de Target:** Isolar o público CMV para garantir que o sinal de inadimplência reflita estritamente o comportamento móvel, eliminando distorções cruzadas de produtos residenciais (NET/DTH).
- **Visão Baseline:** Manter a paridade com o ecossistema amplo, permitindo auditorias comparativas e benchmarks de performance entre a estratégia focada e a visão geral de negócio.
- **Governança de Contrato:** Servir como **contrato único** de conformidade entre Engenharia e Ciência de Dados, entregando ativos imutáveis, homologados e blindados contra *data leakage*.

1.6.2 Ativos GOLD: Estratégia de Expansão e Baseline de Controle

A camada Gold é estruturada em dois conjuntos de ativos para atender simultaneamente à demanda de **Expansão de Mercado** e à de **Estabilidade Transacional**.

a) Estratégia de Expansão (Âncora Bureau)


Ativos especializados para maximizar o volume de treinamento e isolar estritamente o produto móvel.



Ativo	Tipo	Finalidade	Fluxo S3 (Origem → Destino)	Evidências
labels_fpd_bureau	Target	Resposta FPD focado no Público-Alvo (CMV).	Origem: <code>silver/score_bureau_move1</code> Destino: <code>gold/labels_fpd_bureau</code>	Profiling
abt_base_cmvm	ABT	Ativo de Amplitude de Público e Expansão.	Origem: <code>silver/**/* + labels_fpd_bureau</code> Destino: <code>gold/abt_base_cmvm</code>	Profiling

b) Baseline de Controle (Âncora Telco)

Ativos voltados à densidade de sinais comportamentais e paridade com o ecossistema histórico.



Ativo	Tipo	Finalidade	Fluxo S3 (Origem → Destino)	Evidências
labels_fpd	Target	Resposta FPD do Ecossistema (Mix CMV/NET/DTH).	Origem: silver/telco Destino: gold/labels_fpd	 Profiling
abt_base_prod	ABT	Ativo de Densidade Transacional e Controle.	Origem: silver/**/* + labels_fpd Destino: gold/abt_base_prod	 Profiling

💡 Nota de Governança: Diagnóstico Técnico de Cobertura e Atributos

A coexistência dos dois ativos na camada GOLD é fundamentada nos resultados obtidos via *data profiling* das ABTs, comprovando que as características das tabelas Silver foram preservadas para atender a objetivos distintos:

- Massa de Expansão (abt_base_cmvm - 2.6M):

Utiliza o target oriundo da silver/score_bureau_movem. Garante o volume necessário para treinamento focado no **Público-Alvo**, embora apresente **50.3% de nulos** nas colunas com prefixo tel_. É o ativo ideal para garantir a **generalização do modelo** em cenários de prospecção e novos clientes. ( [Profiling](#))

- Densidade de Controle (abt_base_prod - 1.3M):

Utiliza o target oriundo da silver/telco. Atua como o **Padrão de Ouro** para calibração, pois retém **99.9% de preenchimento** nas colunas tel_. Permite validar se os sinais aprendidos pelo algoritmo são consistentes com o **comportamento transacional interno** (rec_, pag_, atr_). ( [Profiling](#))

- Isolamento de Risco por Produto:

O profiling na abt_base_prod identificou que o produto **DTH apresenta 53.4% de FPD**, enquanto o **CMV estabiliza em 21.2%** na abt_base_cmvm. A separação dos ativos garante que a predição para o produto móvel (CMV) não seja contaminada pelo risco extremo detectado em produtos residenciais (NET/DTH).

- Direcionamento Estratégico das Âncoras

A síntese abaixo detalha a **responsabilidade técnica** da arquitetura para garantir tanto a amplitude quanto a fidelidade dos dados:



1.6.3 Governança de Histórico e Versionamento

A utilização do `run_id` como chave de particionamento na camada Gold transcende a organização técnica, atuando como o pilar de **Imutabilidade dos Experimentos**. Cada execução do pipeline gera um snapshot completo da ABT, preservando o estado exato das features e das Janelas de Lookback naquele instante.

Esta estratégia permite:

- **Comparação A/B de Versões:** Permite confrontar a performance de diferentes versões de modelos (ex: v1 vs v2) sobre a mesma base histórica imutável de CMV.
- **Auditoria de Drift:** Comparação histórica entre diferentes versões da ABT CMV para identificar se a queda de performance de um modelo se deve a mudanças no comportamento dos dados do Bureau.
- **Backtesting e Rollback:** Capacidade de revalidar modelos antigos ou reverter para a base exata de um experimento anterior com total determinismo estatístico.

1.7 Estrutura Física de Armazenamento (Padrão Hive)

A organização física segue o padrão Hive para compatibilidade e performance:

```
s3://lake/
├─ raw/
│   └─ {entidade}/
├─ bronze/
│   ├── {entidade}/
│   │   └─ run_id=YYYYMMDD/
│   │       └─ ano_mes=YYYYMM/
│   │           └─ data_0.parquet
│   └─ {dimensao}/
│       └─ dimensao.parquet
├─ silver/
│   └─ {entidade}/
│       └─ run_id=YYYYMMDD/
│           └─ ano_mes=YYYYMM/
│               └─ data_0.parquet
├─ gold/
│   └─ {entidade}/
│       └─ run_id=YYYYMMDD/
│           └─ ano_mes=YYYYMM/
│               └─ data_0.parquet
├─ observability/
│   └─ reports/
│       └─ run_id=YYYYMMDD/
│           ├── pipeline_run_YYYYMMDD.log
│           ├── integrity/
│           ├── profiling/
│           └─ quality/
```

2. Modelo Final CatBoost v1.0 - Veredito Executivo

O modelo final de produção (CatBoost v1.0) representa o resultado de um processo iterativo de modelagem orientado por dois pilares inegociáveis: alta performance preditiva e conformidade ESG irrestrita.

Modelo Campeão: ESG Compliant - Foco Comportamental

O modelo é focado massivamente no comportamento financeiro, de recarga e transacional do cliente na Telco, utilizando a demografia básica (Idade) apenas como linha de base. Variáveis sensíveis de geolocalização e vulnerabilidade social (UF, Região, Auxílio Emergencial, Bolsa Família) foram deliberadamente excluídas do escopo para garantir aderência regulatória, ética e governança corporativa.

2.1 Resultados Consolidados

Métrica	Resultado	Status
KS OOT (Generalização)	34.46%	Acima do Benchmark (33.1%)
Gini OOT	46.62%	Excelente (meta: > 40%)
PSI (Treino vs OOT)	0.0009	População Estável (< 0.10)
Swap-Out Bad Rate	51.41%	Proteção efetiva vs Bureau
Swap-In Bad Rate	33.18%	Expansão controlada
Redução de Risco no Volume Rotacionado	18.23 pp	Impacto direto na carteira

Ver [A.4.3](#) para projeção do impacto em EBITDA e [A.4.4](#) para decomposição do ganho.

2.2 Três Pilares do Veredito

- **Governança e Compliance (ESG):** O algoritmo é "cego" para geolocalização e marcadores de vulnerabilidade social. A expansão da Claro não pratica exclusão financeira baseada em CEP ou classe social.
- **Poder Preditivo Comportamental:** A decisão de crédito é baseada no mérito e na relação histórica do cliente com a Claro (Recargas, Pagamentos, Atrasos), provando matematicamente que a inteligência comportamental interna substitui dados polêmicos.
- **Alta Performance Sustentável:** Mesmo sob rigorosas diretrizes éticas, o modelo de 62 variáveis supera com folga o benchmark do projeto, garantindo lucratividade de forma segura.

3. Decisões Arquiteturais de Modelagem

Documentamos abaixo as decisões técnicas que moldaram o artefato final em produção, priorizando a estabilidade de longo prazo e a performance de negócios.

3.1 Restrições Monotônicas

Decisão: Veto - Degradação de Performance Confirmada

Resultado: A performance no grupo OOT sofreu degradação ao forçar a monotonicidade.

Motivo: As variáveis de telecomunicações possuem relações de risco fortemente não-lineares.

Justificativa: Forçar relação monotônica retira a principal vantagem do Gradient Boosting - encontrar bolsões de exceções comportamentais altamente lucrativas.

3.2 Redução de Dimensionalidade via SHAP

Decisão: Cortes Agressivos Rejeitados - Preservação de 62 Features

Resultado: O ganho computacional não compensou a perda informacional nos splits mais profundos das árvores.

Justificativa: Features comportamentais "marginais" se mostraram vitais para a separação de risco em nichos específicos. A arquitetura CatBoost lida perfeitamente com a dimensionalidade de 62 variáveis.

3.3 Ensembling Tradicional

Decisão: Veto - Trade-off Complexidade vs Ganho Marginal Injustificável

Avaliação: Técnicas de Blending (combinação de múltiplos algoritmos) foram avaliadas.

Motivo do Veto: Manter múltiplas bibliotecas ativas dobra o consumo de RAM, aumenta a latência de inferência e destrói a explicabilidade transparente.

Estratégia: Foco em um único algoritmo "estado da arte" para MLOps simplificado e auditável.

3.4 A Virada de Chave: LightGBM → CatBoost

Esta foi a decisão arquitetural mais impactante do projeto, identificada durante o processo iterativo de modelagem.

Fase	Decisão	Impacto
Modelo Baseline	LightGBM como modelo de referência	Performance inicial competitiva
Experimento Blend	Blend LightGBM + CatBoost testado	LightGBM canibaliza o CatBoost
Diagnóstico	Isolamento revelou superioridade do CatBoost	Tratamento nativo de Target Leakage superior
Decisão Final	100% CatBoost + Otimização Bayesiana	KS OOT 34.46% - Performance definitiva

4. Pipeline de Dados e Configuração do Modelo

4.1 Carga Otimizada da ABT Gold

A carga de dados utiliza DuckDB com Column Projection e Predicate Pushdown, garantindo eficiência de memória e performance. A base final retida contempla 2.633.900 registros com Bad Rate Global de 21.23%.

Parâmetro Técnico	Valor	Objetivo
Origem	<code>abt_base_cmv/**/*.parquet</code>	ABT Gold CMV - base bruta completa (Camada Medallion)
Destino	<code>abt_model_features/**/*.parquet</code>	Serving Layer otimizada para inferência e visualização
Seleção de Colunas	80 variáveis via <code>COLS_NECESSARIAS</code> (62 features)	Column Projection - apenas features necessárias ao CatBoost e Painel Streamlit

4.2 Estratégia de Split - Controle e Temporal

A base foi segmentada em dois níveis para garantir isolamento de contaminação e validação temporal rígida.

Conjunto	Composição	Volume (N)	Bad Rate
Holdout Controle (ZZ/ZX)	CPF <code>mask 5:7</code>	110.268	~21%
Train (80% Out/24–Jan/25)	Out/Sample	1.362.431	20.77%
Test Out-of-Sample (20%)	Out/Sample	340.608	20.77%
OOT (Fev-Mar/25)	Temporal	820.593	20.92%

4.3 Blocos de Features (62 Variáveis)

O vetor de features está organizado em 5 domínios de negócio, garantindo cobertura 360° do perfil de risco do cliente:

#	Bloco	Features (N)	Exemplos de Variáveis
1	Bureau de Crédito	2	<code>bur_score_01</code> <code>bur_score_02</code>
2	Telco	9	<code>tel_var_41</code> <code>tel_var_33</code> <code>tel_var_34</code> <code>tel_var_31</code>
3	Cadastro	5	<code>tempo_conta_dias</code> <code>idade</code> <code>cad_var_05</code> <code>cad_var_16</code> <code>cad_bureau_x_estabilidade</code>
4	Recarga	25	<code>rec_qtd_geral</code> <code>rec_vlr_total_geral</code> <code>rec_tendencia_vlr_l30_l90</code> <code>rec_share_digital</code>
5	Pagamento e Atraso	21	<code>pag_vlr_total_geral</code> <code>pag_taxa_fatura_aberta</code> <code>atr_vlr_max_geral</code> <code>atr_fator_cronico</code>
TOTAL	5 Domínios	62	Cobertura 360° do perfil de risco CMV

[🔗 Book de Variáveis - ABT Model Features](#)

4.4 Hiperparâmetros do Modelo Final


Hiperparâmetro	Valor Otimizado	Justificativa
<code>learning_rate</code>	0.0508	Convergencia gradual, resistencia a overfitting
<code>depth</code>	7	Sweet spot - capacidade x regularizacao
<code>l2_leaf_reg</code>	3.107	Penalização L2 para reduzir variância
<code>random_strength</code>	0.280	Aleatoriedade nos splits para diversidade
<code>subsample</code>	0.849	Bootstrap Bernoulli - reduz correlação de árvores
<code>colsample_bylevel</code>	0.690	Subsampling de features por nível da arvore
<code>iterations</code>	4000 (Best: 2026)	Early stopping no best_iteration
<code>eval_metric</code>	AUC	Otimização da área sob a curva ROC
<code>random_seed</code>	42	Reprodutibilidade garantida

5. Estratégia de Treinamento Incremental (Waterfall de KS)

Para quantificar o valor informacional de cada domínio de dados, adotamos um protocolo de Forward Selection com monitoramento do KS em Train, Test e OOT a cada bloco adicionado. Esta análise é o artefato mais relevante para demonstrar a contribuição de cada fonte de dados.

5.1 Resultados do Waterfall - Evolução Incremental por Bloco

Bloco Adicionado	Features	KS Train	KS Test	KS OOT	Delta KS OOT
Score 1	1	27.28%	27.04%	26.10%	+26.10pp
Score 2	2	32.87%	32.60%	30.71%	+4.60pp
Telco	11	33.32%	32.83%	30.94%	+0.24pp
Cadastro	16	33.77%	32.95%	31.19%	+0.25pp
Recarga	41	38.35%	36.06%	34.01%	+2.82pp
Pagamento e Atraso	62	39.10%	36.45%	34.46%	+0.45pp



Evolução Incremental do KS: valor adicionado por bloco de informação.

5.2 Contribuição por Fonte de Dados

Fonte	Contribuição	Observação Estratégica
Bureau (Score 1 + 2)	+30.71pp	Ancora principal - consolidado do histórico de mercado
Recarga	+2.82pp	Virada de chave - sinal comportamental interno de maior impacto pos-bureau
Pagamento e Atraso	+0.45pp	Histórico transacional consolidado
Cadastro	+0.25pp	Âncora demográfica (Idade como linha de base ESG)
Telco	+0.24pp	Sinais de consumo de rede - valor complementar
KS OOT FINAL	34.46%	Best Iteration: 2026 árvores



Insight - O Poder da Recarga

A variável Recarga representou um salto de +2.82pp de KS OOT - o maior ganho individual após o Bureau. Este resultado valida a hipótese central do projeto: o comportamento transacional interno da Claro (frequência, valor, canal e dependência de recargas) e um preditor de crédito de primeira ordem, capaz de capturar nuances comportamentais que o score de bureau não consegue detectar.

6. Resultados e Métricas de Performance

6.1 Métricas Globais - Modelo Final CatBoost v1.0


Métrica	Train	Test	OOT	Status
KS	39.10%	36.45%	34.46%	Acima do Benchmark (33.1%)
Gini	52.78%	49.28%	46.62%	Acima da meta (> 40%)
AUC	0.764	0.746	0.733	Acima da meta (> 0.65)



6.2 Análise de Decis - Gains Table (OOT)

A Gains Table do conjunto OOT demonstra monotonicidade perfeita e alta capacidade de concentração de risco nos decis superiores:

Decil	Bad Rate Observada	Acumulado Good	Acumulado Bad	Razão vs Média
1 (Menor Risco)	~4.9%	Alto	Baixo	0.23x
5 (Médio)	~15.2% (Média global)	Médio	Médio	0.72x
10 (Maior Risco)	~52.4%	Baixo	Alto	2.49x



Os 3 decis de maior risco (8, 9, 10) com bad rates de 28.8%, 36.6% e 52.4% concentram a maioria dos eventos de inadimplência, permitindo políticas de corte eficazes.



Análise de Risco por Decil (OOT): monotonicidade perfeita de 4.9% a 52.4%.

6.3 Feature Importance (CatBoost Native)

O ranking de importância de variáveis confirma a importância das variáveis comportamentais de recarga como principais contribuidores internos.

Top 15 Drivers: O Peso do Comportamento Interno


Impacto das variáveis internas de recarga e uso (excluindo bureaus e demografia).



6.4 Calibração de Probabilidade - Brier Score e Reliability Diagram

Complementando as métricas de separação (KS/Gini/AUC), a análise de calibração avalia se as probabilidades previstas pelo modelo são interpretáveis como estimativas reais de risco de inadimplência - premissa fundamental para a validade das projeções financeiras de Swap-In/Swap-Out apresentadas na [Seção 8](#), e [Apêndice A.4](#).

Métrica	Train	Test	OOT	Referência
Brier Score	0.1373	0.1419	0.1449	Nulo: 0.1654
Brier Skill Score	-	-	12.38%	Meta: > 10%



O Reliability Diagram demonstra que as probabilidades previstas acompanham o bad rate real observado em toda a faixa de decisão relevante (0% a 50% de score), com as três curvas - Train, Test e OOT - praticamente sobrepostas. O desvio observado acima de 50% de probabilidade prevista é estatisticamente esperado dado o volume reduzido de eventos nessa faixa extrema, e não impacta nenhuma decisão comercial relevante, pois corresponde ao segmento de rejeição consensual entre modelo e bureau (quadrante 4 da [Seção 8.1](#)).

O Brier Skill Score de **12.38%** indica que o modelo é 12.4% mais preciso que um estimador ingênuo pela média, resultado dentro do intervalo esperado para modelos comportamentais de crédito de varejo (referência de mercado: 10%–20%). A degradação suave de Train → OOT (0.1373 → 0.1449) espelha o comportamento do KS, confirmando ausência de overfitting também na dimensão de calibração.


7. Validação de Estabilidade

7.1 Population Stability Index (PSI)

PSI Score Global (Treino vs OOT): 0.0009

Classificação: POPULAÇÃO ESTÁVEL (limite < 0.10)

A distribuição das probabilidades previstas se mantém idêntica entre os períodos de treino e OOT. Isso indica que o modelo não sofreu degradação temporal - comportamento ideal para produção.




Population Stability Index (PSI): 0.0009 - distribuições de Train e OOT praticamente sobrepostas.

7.2 PSI por Feature (Data Drift)

A análise feature-level avaliou a estabilidade de distribuição de cada variável entre Train e OOT. Todas as features monitoradas mantiveram PSI < 0.10, confirmando ausência de drift significativo nas fontes de dados.

Faixa de PSI	Classificação	Ação	Status na Base
< 0.10	Estável	Nenhuma ação necessária	Todas as features monitoradas
0.10 - 0.25	Monitorar	Investigar tendência	Nenhuma feature crítica
> 0.25	Crítico	Re-treinamento necessário	Nenhuma feature detectada



Data Drift: PSI por Feature. Todas as variáveis monitoradas estão abaixo do limite de atenção (0.10).


7.3 Bootstrap - Intervalos de Confiança do KS (1000 reamostras)

A análise de bootstrap (1000 iterações) foi conduzida para validar a robustez estatística da performance e confirmar que as diferenças entre conjuntos não são artefatos de variação amostral.

Conclusão: Distribuições Estatisticamente Compactas e Separadas

As distribuições violino do KS nos 3 conjuntos (Train 39.11%, Test 36.47%, OOT 34.47%) são compactas e bem definidas, confirmando que:

- A performance não é resultado de overfitting a nenhum período específico.
- O modelo mantém poder discriminatório robusto independente da amostra avaliada.
- A degradação Train -> OOT de ~4.64pp está dentro do esperado estatisticamente.




Robustez Estatística: Intervalo de Confiança do KS (Bootstrap 1000x). Distribuições compactas e estáveis.

8. Análise de Valor de Negócio - Swap-In / Swap-Out

Para demonstrar o valor prático do modelo na tomada de decisão de crédito, foi conduzida uma simulação de Swap In/Swap-Out com cutoff de aprovação em 70%, aplicado sobre o Grupo Controle (Holdout).

8.1 Matriz de Decisão - Resultado Completo

Segmento	Volume	% Base	Bad Rate	Interpretação
1. Ambos Aprovam (Modelo + Bureau)	70.313	63.8%	17.46%	Consenso de aprovação - risco base
2. Swap-In (Oportunidade)	6.874	6.2%	33.18%	Reprovados Bureau, aprovados Modelo - oportunidade
3. Swap-Out (Proteção)	7.103	6.4%	51.41%	Aprovados Bureau, barrados Modelo - proteção
4. Ambos Rejeitam	25.978	23.6%	60.45%	Consenso de rejeição - alto risco



Fronteira de Decisão: onde o Modelo comportamental desafia o Bureau. Quadrantes de Swap-In (verde) e Swap-Out (vermelho)

8.2 Impacto Direto na Carteira

Impacto Direto na Carteira

Redução Real de Risco no Volume Rotacionado: 18.23 pontos percentuais.

O modelo demonstra capacidade de trocar clientes piores por melhores:

- Swap-Out Bad Rate (51.41%) vs Swap-In Bad Rate (33.18%) = Delta de 18.23pp.
- A diferença de 18.23pp entre os segmentos representa o valor incremental do modelo comportamental sobre o bureau tradicional na decisão de concessão de crédito.



A quantificação financeira completa, incluindo projeção de EBITDA nacional em 12 meses e decomposição do ganho incremental, está detalhada no [Apêndice A.4](#).

9. Plano de Monitoramento em Produção

A sustentabilidade do Behavior Score CMV em produção depende de um sistema de monitoramento ativo, capaz de detectar degradações antes que elas se traduzam em perda financeira mensurável. Com um ganho incremental de R\$6,3M projetado para os primeiros 12 meses de operação, cada ponto percentual de degradação não detectada representa erosão direta de resultado. O plano abaixo estrutura a governança em três camadas: sinais de alerta, diagnóstico de causa e protocolo de resposta.

9.1 Gatilhos de Alerta e Limiares Críticos

O modelo deve ser monitorado mensalmente por safra, com os seguintes limiares:

Métrica	Limiar Alerta	Limiar Crítico	Ação
PSI do Score	> 0.10	> 0.25	Investigar drift; avaliar re-treinamento
Degradação de KS (vs OOT)	> 3pp	> 5pp	Investigar fonte; checar pipeline Gold
PSI por Feature	> 0.10	> 0.25	Investigar fonte; checar pipeline Gold
Bad Rate Observada	+3pp vs baseline	+5pp vs baseline	Calibrar cutoff; alertar negócio

Referência de baseline: PSI global atual de 0.0009, KS OOT de 34.46% e Bad Rate de 20.92% - estabelecidos na safra de validação Fev-Mar/25.

9.2 Interpretação Financeira dos Limiares

Os limiares acima não são arbitrários - cada um tem impacto direto sobre o ganho incremental projetado.

Uma **degradação de KS acima de 3pp** (de 34.46% para abaixo de 31.46%) significa perda de poder discriminatório suficiente para comprometer a fronteira de decisão do Swap-In/Swap-Out. Com 6.874 clientes no quadrante verde e 7.103 no vermelho no Grupo Controle, essa degradação pode silenciosamente reclassificar centenas de clientes para os quadrantes errados por mês.

Um **aumento de Bad Rate acima de +3pp** (de 20.92% para acima de 23.92%) sinaliza que o volume de Swap-Out efetivo está sendo subestimado - diretamente reduzindo os R\$2,1M de PDD evitada projetados no Bridge de rentabilidade (A.6.5).

Um **PSI de feature acima de 0.10** nas variáveis de recarga - que sozinhas contribuíram com +2.82pp de KS no Waterfall (seção 5.2) - indica mudança comportamental na base que pode invalidar os preditores mais valiosos do modelo antes de qualquer degradação visível no score global.

9.3 Cadência e Responsabilidades

Frequência	Atividade	Responsável
Mensal	Cálculo de PSI global do score e por feature	Engenharia de Dados
Mensal	Cálculo de KS e Bad Rate por safra	Ciência de Dados
Mensal	Atualização do painel de observabilidade	Engenharia de Dados
Trimestral	Revisão completa das janelas de lookback	Ciência de Dados
Trimestral	Revisão dos limiares de alerta vs baseline atualizado	Ciência de Dados + Negócio
Sob demanda	Re-treinamento em caso de limiar crítico atingido	Ciência de Dados

9.4 Protocolo de Diagnóstico em Caso de Alerta

Quando um limiar de alerta for atingido, o diagnóstico deve seguir a sequência abaixo antes de qualquer ação de re-treinamento:

Passo 1 - Isolar a camada afetada. Verificar se o drift vem de mudança na distribuição dos dados de entrada (PSI por feature) ou de degradação real do poder preditivo (KS). São causas distintas com soluções distintas.

Passo 2 - Checar integridade do pipeline Gold. Verificar se as janelas de lookback (30/60/90 dias) estão sendo calculadas corretamente e se a camada Silver das entidades de Recarga e Pagamento - as de maior contribuição preditiva - estão íntegras. Consultar os logs de observabilidade do run_id correspondente.

Passo 3 - Avaliar o impacto no cutoff. Antes de re-treinar, verificar se um ajuste no cutoff (de P70 para P65 ou P75) é suficiente para reequilibrar o Bad Rate observado. A zona plana da curva de custo total entre 70% e 80% (A.6.3) garante margem de ajuste sem perda expressiva de resultado.

Passo 4 - Acionar re-treinamento apenas se necessário. O re-treinamento deve ser acionado somente quando PSI global ultrapassar 0.25 ou KS degradar mais de 5pp - sinais de que o comportamento da base mudou estruturalmente, não apenas sazonalmente.

9.5 Sinais de Atenção Específicos por Domínio

Além das métricas globais, três domínios merecem monitoramento individualizado dado seu peso preditivo demonstrado no Waterfall de KS (seção 5.2):

Recarga (+2.82pp de KS): Monitorar mensalmente o PSI das variáveis `rec_vlr_bonus_geral`, `rec_qtd_plat_autoc` e `rec_share_status_ativo` - as três de maior poder preditivo no ranking de feature importance (seção 6.3). Mudanças em campanhas comerciais de recarga ou alterações de plano podem impactar essas variáveis rapidamente.

Bureau (+30.71pp de KS acumulado): Monitorar o PSI das variáveis `bur_score_01` e `bur_score_02`. Alterações metodológicas nos bureaus de mercado - que ocorrem periodicamente - podem introduzir drift externo invisível ao pipeline interno.

Atraso (`atr_max_aging_divida_190d`): Segunda feature mais estável no monitoramento de PSI por feature (0.0533 - ainda dentro do limite seguro), mas com maior sensibilidade a ciclos econômicos. Monitorar com atenção em períodos de alta de juros ou desemprego.

9.6 Critério de Desativação do Modelo

O modelo deve ser considerado para substituição imediata caso **dois ou mais** dos seguintes eventos ocorram simultaneamente em uma mesma safra:

- KS OOT abaixo de 29% (degradação de 5pp+ vs baseline)
- PSI global do score acima de 0.25
- Bad Rate observado acima de 26% (+5pp vs baseline de 20.92%)
- PSI de feature crítica (Recarga ou Bureau) acima de 0.25

A coexistência de múltiplos sinais críticos indica mudança estrutural na base, não ajustável por calibração de cutoff - exigindo re-treinamento completo com nova safra de referência.

A.1 Data Architecture - Estratégia de Cloud Readiness (OCI Execution)

Implementação da arquitetura de dados, concebida sob o paradigma **Cloud Ready**. A infraestrutura da **Oracle Cloud Infrastructure (OCI)** atua como a plataforma de execução otimizada para o motor de governança e processamento DuckDB.

A.1.1 Visão Geral da Estratégia: Core & Ops

Para atingir a máxima maturidade arquitetural, separamos a **Inteligência** da **Sustentação**. Essa separação permite que o motor de dados seja agnóstico, enquanto a operação é otimizada para a nuvem através de pilares de **Cloud Readiness**.

-  **Core (The Engine):** Responsável pela lógica de negócio e transformação. Atua como o Worker que executa a arquitetura Medallion e assegura a integridade absoluta dos dados. É o motor que consolida uma Governança Nativa, onde contratos de dados e regras de qualidade são aplicados diretamente no fluxo de execução.

Nota de Decisão Arquitetural (Motor de Processamento)

A escolha do DuckDB para o processamento e escoragem do nosso projeto baseia-se na eficiência superior para volumetrias que não exigem, em primeira instância, computação distribuída. Enquanto o Spark introduz uma latência significativa devido ao gerenciamento de cluster e serialização de dados, o DuckDB opera como um motor OLAP vetorial in-process, eliminando esse overhead operacional. No contexto da nossa amostra, essa arquitetura permite execuções de altíssima performance diretamente na memória configurada da instância, facilitando a integração nativa com o ecossistema que já utilizamos. Além disso, a simplicidade de manter o DuckDB em um ambiente containerizado via Docker reforça nossa estratégia de Cloud Readiness, garantindo agilidade no deploy e menor custo computacional sem sacrificar o poder de processamento necessário para o tratamento dos dados e validação do modelo

-  **Ops (The Platform):** Responsável pelo **Provisionamento (IaC)** via Terraform e **Orquestração** via Airflow. É o que viabiliza a execução do Core com segurança, permitindo atualizações de inteligência sem a necessidade de redeploy da infraestrutura.


Nota de Decisão Arquitetural (Cloud Readiness)

Embora a OCI ofereça serviços gerenciados como OCI Container Instances e OKE (Kubernetes), optamos estrategicamente pela execução via Docker Compose dentro de OCI Compute. Esta decisão foi tomada para garantir a Portabilidade Total (Cloud Readiness): a solução não possui "lock-in" com serviços proprietários de orquestração da nuvem, permitindo que todo o ecossistema (Airflow + Workers + Ingestão) seja migrado para qualquer provedor Cloud ou ambiente On-premises apenas movendo o arquivo de composição, mantendo a simplicidade operacional sem sacrificar o isolamento de processos.

A.1.2 Fases do Ciclo de Vida Operacional

A execução na OCI foi estruturada em um pipeline de 3 grandes fases totalmente automatizadas:

- **Fase 1: Provisionamento Imutável (Terraform):** Toda a infraestrutura é erguida via código, garantindo reprodutibilidade.
 - **Networking:** VCN isolada com Subnets públicas e Security Lists.
 - **Identity (IAM):** Implementação de **Dynamic Groups** e **Instance Principals**, permitindo que a VM gerencie objetos no Bucket sem chaves fixas.
 - **Storage:** Bucket `lake-squad3` configurado com API S3-Compatible para integração nativa com DuckDB.
- **Fase 2: Bootstrap & Integração (Cloud-Init + Docker):** No momento do boot da instância, o script `cloud-init.sh` prepara o ambiente.
 - **Performance Path:** Criação do diretório `/mnt/nvme/duckdb_temp` no host com permissões otimizadas para o motor DuckDB.
 - **Volume Mapping:** O Core é montado como um volume persistente.
- **Fase 3: Orquestração Unificada (Airflow):** O Airflow assume o papel de maestro.
 - A orquestração não apenas dispara as transformações de dados (Medallion), mas agora também acopla a **Ingestão Híbrida** (MinIO → OCI) no mesmo fluxo, garantindo que o processamento só inicie após a garantia de dados brutos renovados.



A.1.3 Governança e Segurança (Policy as Code)

A arquitetura transporta os pilares de **Cloud Readiness** para a nuvem de forma nativa:

- **Segurança Zero-Trust:** Uso de *Instance Principals*. A identidade da VM é sua própria credencial de acesso ao Data Lake.
 - **Otimização de Hardware:** Configuração dinâmica de limites severos para máxima performance: `DUCKDB_MEMORY_LIMIT=48GB` e `DUCKDB_THREADS=12` injetados dinamicamente via variáveis de ambiente.
 - **Isolamento de Processos:** Separação clara entre logs de orquestração (Airflow) e logs de processamento (Core/DuckDB).
-

A.2 Provisionamento IaC (Terraform) - Infraestrutura como Código

O provisionamento é totalmente automatizado via Terraform, garantindo um ambiente escalável, seguro e reprodutível para o ecossistema Claro.

A.2.1 Desenho da Solução

Nossa infraestrutura foi desenhada seguindo o princípio de desacoplamento entre **Compute** (Processamento) e **Storage** (Armazenamento), permitindo escalabilidade independente

- **Rede e Segurança (Networking):**
 - **Localização:** Definido no arquivo `terraform/network.tf`.
 - **VCN:** Rede virtual privada dedicada (`squad3-vcn`) com bloco CIDR `10.0.0.0/16`.
 - **Firewall (Security List):** Porta **22** (Acesso administrativo via SSH) Porta **8080** (Interface web do Apache Airflow) e Portas **8501/8502** (Data App Streamlit).
 - **Saída para Internet:** Internet Gateway configurado para permitir atualizações de sistema e download de bibliotecas Python/Docker.
- **Motor de Processamento (Ops Engine):**
 - **Localização:** Definido no arquivo `terraform/compute.tf`.
 - **Hardware:** Instância **VM.Standard.E3.Flex** com **8 OCPUs** e **64GB de RAM**.
 - **Storage Local:** Boot volume de **200GB** (SSD) para suportar picos de processamento do DuckDB (cache em disco).
 - **Bootstrap:** O arquivo `terraform/scripts/cloud-init.sh` automatiza a instalação do Docker e Docker Compose no primeiro boot da máquina.
- **Data Lakehouse (OCI Object Storage):**
 - **Localização:** Definido no arquivo `terraform/storage.tf`.
 - **Storage:** Bucket `lake-squad3` configurado como **Standard Tier** para baixa latência.
 - **Organização:** Estruturado para suportar a arquitetura Medallion (Bronze, Silver e Gold)

A.2.2 Identidade e Governança (IAM)

A segurança da Squad 3 é baseada no princípio do privilégio mínimo.

- **Instance Principal (Automação):** Utilizamos **Dynamic Groups** definidos no `terraform/iam.tf`. A VM do Airflow tem permissão nata para gerenciar objetos no Bucket via políticas de IAM. Isso elimina a necessidade de armazenar chaves de acesso (`AWS_ACCESS_KEY`) dentro do código ou do servidor.

- **Gestão de Membros (Acessos Humanos):**

- **Engenharia de Dados (squad3-eng-group):** Acesso administrativo ao compartimento (Rafael, Fred e Ronaldo).
- **Analytics/Cientistas (squad3-analytics-group):** Acesso restrito de leitura ao Data Lake (Lucas, Carlos, Lazza, Gustavo e Michele).

A.2.3 Estrutura do Repositório (IaC)

A organização modular do diretório `terraform/` garante a manutenção e clareza do projeto:

Arquivo / Diretório	Função Principal
<code>main.tf</code>	Provedor: Configuração da conexão e autenticação com a OCI.
<code>network.tf</code>	Rede: Definição da VCN, Subnets, Gateways e Firewalls.
<code>compute.tf</code>	Processamento: Provisionamento da Instância VM.Standard.E3.Flex
<code>iam.tf</code>	Identidade: Gestão de Dynamic Groups, Usuários e Políticas.
<code>storage.tf</code>	Persistência: Provisionamento do Bucket (Object Storage).
<code>outputs.tf</code>	Saídas: Exibição de IPs e geração de chaves para a Squad.
<code>variables.tf</code>	Parametrização: Declaração das variáveis globais do projeto.
<code>terraform.tfvars</code>	Valores Privados: OCIDs e segredos reais (Não versionado).
<code>acessos_squad3/</code>	Secrets: Diretório gerado contendo as chaves .pem e credenciais S3 (Não versionado).
<code>scripts/cloud-init.sh</code>	Bootstrap: Instalação automática do Docker/Airflow na VM
<code>scripts/verify-setup.sh</code>	Validação: Health check pós-deploy da infraestrutura.
<code>scripts/teardown.sh</code>	Limpeza: Procedimentos de destruição e reset do ambiente

A.2.4 Otimização de Performance

O ambiente foi configurado para reduzir o tempo de pipeline através de:

- **Tuning de Memória:** Alocação de 16GB de RAM dedicada ao DuckDB para operações in-memory.
- **Tuning de CPU:** Configuração de 6 Threads paralelas para compressão Parquet e transformações.
- **S3 Compat:** Integração de alta velocidade entre a VM e o Bucket via API S3 Nativa da Oracle Cloud.

A.3 Orquestração de Fluxos (Airflow) - DAGs e Estratégia de Agendamento

O orquestrador é responsável por garantir que o código esteja atualizado, o ambiente configurado, os dados processados na ordem correta e a observabilidade de custos (FinOps) mantida.

A.3.1 Detalhamento das DAGs e Tasks

A operação baseia-se em 3 fluxos principais, operando com o fuso horário da máquina (`sa-saopaulo-1`):

core_bootstrap (Preparação do terreno e Deploy): Garante que o ambiente de execução seja um espelho fiel do repositório de código e que os limites de hardware estejam configurados

- **sync_core_repository**: Realiza o *fetch* e *reset -hard* da branch `main` no repositório Core via SSH, eliminando conflitos de arquivos locais.
- **setup_core_environment**: Injeta dinamicamente as credenciais da OCI e estabelece os hard-limits de performance do DuckDB (`48GB RAM, 12 Threads`), além de configurar as políticas de retenção das camadas do Lakehouse.
- **install_core_dependencies**: Gerencia o Virtual Environment (`venv`) e executa o `pip install` para garantir pacotes atualizados.

core_pipeline (O Motor Unificado): Sincroniza a origem com o destino e executa as transformações, consolidando Ingestão e Engenharia na mesma DAG para evitar dependências órfãs.

- **sync_raw_layer**: Task em Python que atua como ponte. Move dados brutos do MinIO legado direto para o Object Storage (Raw) da OCI.
- **execute_unified_pipeline**: Dispara o script bash `/bin/run_pipeline.sh` que executa toda a arquitetura Medallion (Bronze → Silver → Gold).


oci_reports_sync (Observabilidade e FinOps): Nova DAG estratégica para governança de custos na nuvem.

- **Objetivo**: Garante que relatórios de *billing* e inventário da OCI sejam extraídos via SDK e persistidos, provendo visibilidade constante sobre o consumo computacional do projeto na Oracle.

A.3.2 Estratégia de Janelas de Execução (Schedules)

A arquitetura de horários foi desenhada para evitar concorrência de recursos e garantir a previsibilidade:

DAG	Agendamento	Timezone Local	Papel na Cadeia
<code>oci_reports_sync</code>	Diário (Contínuo)	A cada 6 horas	Monitoramento FinOps e Inventário Cloud.
<code>core_bootstrap</code>	Semanal (Seg)	02:00	Atualiza o software, resolve pendências e reseta o ambiente.
<code>core_pipeline</code>	Mensal (Dia 1º)	03:00	Ingestão e processamento da safra mensal após a garantia de deploy do <code>core_bootstrap</code> .



A.3.3 Política de Retenção e Run IDs

Cada execução do pipeline é rastreada por um **Run ID** exclusivo, garantindo a rastreabilidade da safra de dados.

- **Isolamento por Run:** Cada execução gera uma linhagem de dados específica, blindando a integridade do histórico do Lakehouse.
- **Retenção Agressiva (Otimização de Custos):** O `core_bootstrap` impõe as variáveis de ambiente `BRONZE_MAX_RUNS=1`, `SILVER_MAX_RUNS=1` e `GOLD_MAX_RUNS=1`.
- **Vantagem:** O sistema mantém persistida **apenas a última execução bem-sucedida** de cada camada materializada, evitando inchaço desnecessário no Object Storage e mantendo o custo de armazenamento em níveis mínimos aceitáveis para a operação em nuvem.

A.4 Análise de Impacto Financeiro - Projeção Nacional 12 Meses

💡 Nota de Transparência Metodológica - Premissas Financeiras

As premissas econômicas utilizadas nas projeções têm origens distintas e rastreáveis:

ARPU Controle (R\$59,00): Extraído diretamente da camada Silver (`lake/silver/pagamento`), calculado como média de `val_pagamento_fatura` com filtro de sanidade entre R\$5 e R\$300, garantindo exclusão de valores atípicos.

ARPU Pré-Pago (R\$30,00): Calculado como mediana da recarga mensal por CPF/mês (`lake/silver/recarga`), usando mediana em vez de média para robustez contra heavy users.


Upsell Incremental (R\$29,00): Derivado diretamente da subtração dos dois ARPUs acima - ambos oriundos da mesma base de amostra, garantindo consistência interna.

Taxa de Conversão (3%): Valor empírico calculado da Silver resultou em 1,28% (janela de 3 meses, sem campanha ativa) - interpretado como lower bound orgânico. O valor de 3% adotado é benchmark de mercado para migração Pré→Controle (referência: relatórios Teleco/Anatel), conservador em relação ao potencial com campanha ativa.

Base Elegível (35M): Baseado em balanço oficial da Claro. O pico histórico recente foi de 35,6M no 1T24;

A.4.1 Validação Financeira: Comprovação do Efeito Swap


Para provar que o efeito Swap gera resultado financeiro real - e não apenas teórico - isolamos o Grupo Controle (dados nunca vistos pelo modelo) e aplicamos um fair-play técnico: forçamos ambos os modelos a aprovar exatamente o mesmo volume de clientes. Com igualdade de condições no eixo X (taxa de aprovação de 50% a 90%), a linha verde sólida representa a rentabilidade líquida acumulada (LTV) gerada pelo Behavior Score; a linha vermelha pontilhada representa o Bureau legado. A área preenchida entre as duas curvas - a "boca de jacaré" - é o lucro incremental puro, gerado exclusivamente pela troca de inteligência, sem aprovar mais pessoas nem gastar mais em marketing. No ponto ótimo de 70% de aprovação, o ganho validado é de +3,6% de rentabilidade líquida (Behavior Score: R\$576.563 vs Bureau: R\$556.592).



Validação financeira no Grupo Controle: descolamento de receita líquida entre o Behavior Score (verde) e o Bureau legado (vermelho pontilhado). Taxa de conversão: 3% (benchmark Teleco/Anatel). Upsell incremental: R\$29,00/mês (ARPU Controle R\$59 vs Pré-Pago R\$30). Ganho de +3,6% no ponto ótimo de 70% de aprovação.

A.4.2 Otimização do Corte: Matriz de Custo da Decisão


Com o ganho validado na amostra, o próximo passo foi encontrar matematicamente o ponto de corte que maximiza o resultado na escala nacional (35 milhões de clientes elegíveis). Dois custos opostos competem entre si: o **Custo de Risco** (linha vermelha) - quanto mais se aprova, maior a provisão de PDD; e o **Custo de Oportunidade** (linha azul) - quanto menos se aprova, mais receita de upsell é desperdiçada. A soma dos dois forma o **Custo Total da Decisão** (linha pontilhada preta), cuja curva resulta em um vale. O fundo desse vale - o ponto de menor custo total projetado (~R\$40M) - ocorre precisamente em **70% de aprovação**, confirmando matematicamente o mesmo cutoff identificado na análise de rentabilidade. A curva permanece plana entre 70% e 80%, provando que a decisão é robusta a variações operacionais.



Matriz de Custo da Decisão em escala nacional (TAM: 35M clientes). Ponto ótimo de aprovação: 70% - equilíbrio entre Custo de Risco (PDD) e Custo de Oportunidade (upsell). Desperdício minimizado: ~R\$40M. Zona plana entre 70–80% confirma robustez da política. Dois métodos independentes - Boca de Jacaré (A.4.1) e Custo Total - convergem para o mesmo cutoff. Ver cutoff P70 na seção 8.1.

A.4.3 Projeção de EBITDA Nacional: 12 Meses de Operação


Aplicando a política de 70% de aprovação sobre a base nacional elegível e projetando 12 meses de operação, o Behavior Score leva a Claro a um EBITDA acumulado de **R\$183M**, contra **R\$176,7M** do Bureau legado. O espaçamento entre as curvas cresce ao longo do tempo porque o modelo não apenas aprova melhor no primeiro mês - ele evita inadimplências que no Bureau se acumulariam ao longo do LTV de cada cliente. O ganho incremental líquido de **R\$6,3M** é gerado exclusivamente pela substituição da inteligência de crédito, sem nenhum aumento de volume aprovado nem de investimento em marketing.



Projeção de EBITDA acumulado em 12 meses de operação - Behavior Score (verde) vs Bureau legado (vermelho pontilhado). Base: 35M clientes elegíveis, política de 70% de aprovação, taxa de conversão de 3%. Behavior Score: R\$183M | Bureau: R\$176,7M | Ganho incremental: +R\$6,3M. A decomposição do ganho está detalhada em A.6.5.

A.4.4 Decomposição do Ganho: Bridge Waterfall R\$6,3M


Os R\$6,3M de ganho incremental têm duas origens distintas e complementares, decompostas no gráfico de cascata abaixo. **R\$4,2M (Upsell Net)** representam o ganho do ataque: são os clientes do Swap-In - bons pagadores que o Bureau rejeitaria - resgatados pelo modelo. Cada um deles paga R\$29/mês a mais que no Pré-Pago, durante 12 meses, na escala nacional. **R\$2,1M (PDD Net)** representam o ganho da defesa: são os clientes do Swap-Out - inadimplentes mascarados que o Bureau aprovaria - bloqueados antecipadamente pelo modelo. Cada um representaria 3 meses de ARPU Controle perdido em provisão. Dois terços do ganho vêm de vender melhor. Um terço vem de cobrar melhor.



Bridge de rentabilidade: decomposição do ganho incremental de R\$6,3M. Upsell Net (Swap-In): +R\$4,2M em receita nova - bons pagadores resgatados do Bureau. PDD Net (Swap-Out): +R\$2,1M em provisões evitadas - inadimplentes bloqueados antecipadamente. Total: R\$4,2M + R\$2,1M = R\$6,3M.

A.4.5 Elasticidade Comercial: Sensibilidade da Conversão


O cenário base dos R\$6,3M foi calculado com taxa de conversão de **3%** - referência conservadora calibrada em benchmark de mercado (Teleco/Anatel). O gráfico abaixo simula o impacto financeiro caso a área comercial decida escalar campanhas, variando a conversão de 1% a 6%. A relação é linear: dobrar a conversão dobra o resultado. No cenário de **6% de conversão**, o EBITDA incremental salta para **R\$12,7M**. O ponto crítico está na linha verde: a proteção contra inadimplência (PDD evitada) cresce proporcionalmente ao volume de vendas, atingindo R\$4,3M no cenário agressivo. É possível pisar no acelerador comercial sem risco de explosão da PDD - o modelo escala de forma segura.



Análise de sensibilidade: EBITDA incremental (barras azuis, eixo esquerdo) e PDD evitada (linha verde, eixo direito) em função da taxa de conversão da campanha (1% a 6%). Cenário base: 3% → R\$6,3M. Cenário agressivo: 6% → R\$12,7M. PDD protegida acompanha proporcionalmente: R\$4,3M no cenário máximo.

A.4.6 Estratégia CRM: Tierização por Rating A-E

O modelo entrega uma probabilidade contínua para cada cliente, não uma decisão binária. Essa probabilidade foi traduzida em **5 ratings acionáveis (A a E)** para o time comercial, cada um com estratégia de abordagem distinta. O **Rating A** concentra R\$65,6M de EBITDA potencial com inadimplência residual de apenas 6,8% - campanha agressiva, melhor oferta, prioridade máxima. Os **Ratings B e C** sustentam R\$57,4M e R\$44,4M respectivamente, com risco ainda controlado. O **Rating D** exige oferta conservadora com limite reduzido. O **Rating E**, apesar de marginalmente positivo no papel (R\$1,9M), apresenta **64,5% de FPD** - ROI 34 vezes inferior ao Rating A, com custo operacional de cobrança e churn não modelado: **bloqueio total nas campanhas**. Os segmentos A, B e C concentram 86% do lucro projetado com risco abaixo de 26%. A política de 70% captura integralmente esses três tiers, parte do D e exclui o E.



Estratégia de segmentação CRM: EBITDA incremental projetado (barras, eixo esquerdo) e taxa de inadimplência FPD (linha pontilhada, eixo direito) por Rating A–E. Potencial total da base: R\$195,9M. Política de 70% seleciona A+B+C integralmente e parte do D. Rating E: bloqueio preventivo (FPD 64,5%, ROI 34x inferior ao Rating A).

Nota de Fechamento

*Chegamos ao final da entrega de uma solução de Credit Scoring comportamental ponta a ponta, construída sobre três pilares que se reforçam mutuamente: **arquitetura industrial, ciência de dados responsável e impacto financeiro quantificado.***

Do ponto de vista técnico, a arquitetura Medallion sobre infraestrutura OCI - orquestrada via Airflow, provisionada via Terraform e processada via DuckDB - garante rastreabilidade completa, reprodutibilidade histórica e portabilidade total, sem dependência de serviços proprietários de nuvem. Cada decisão arquitetural registrada neste documento - dos vetos técnicos às escolhas de infraestrutura - foi tomada com um objetivo único: entregar um motor de decisão escalável, auditável e pronto para produção.

Do ponto de vista da modelagem, o CatBoost v1.0 supera o benchmark do projeto em todas as frentes: KS OOT de 34.46% (benchmark 33.1%), Gini OOT de 46.62% (meta >40%) e PSI global de 0.0009 - população virtualmente estável entre treino e safra futura. A robustez estatística foi confirmada via Bootstrap 1000x, com intervalos de confiança compactos e separados entre Train, Test e OOT. O modelo é construído sobre 71% de inteligência comportamental interna da Claro - recargas, pagamentos, atrasos - e deliberadamente cego para geolocalização e marcadores de vulnerabilidade social, garantindo aderência irrestrita a critérios ESG sem sacrifício de performance.

*Do ponto de vista do negócio, a análise completa de impacto financeiro - da validação no Grupo Controle até a tierização CRM - confirma que o Behavior Score gera **R\$6,3M de ganho incremental líquido em 12 meses** de operação na escala nacional, com potencial de **R\$12,7M no cenário de conversão agressiva.** O ganho é estruturalmente equilibrado: dois terços vêm do ataque - R\$4,2M em receita nova via Swap-In - e um terço vem da defesa - R\$2,1M em PDD evitada via Swap-Out. A política de 70% de aprovação, validada por dois métodos independentes (Boca de Jacaré e Curva de Custo Total), garante que o crescimento comercial escala de forma segura, sem explosão de inadimplência.*

Essas projeções são sustentáveis em um cenário onde as premissas de taxa de conversão (3%, calibrada em benchmark Teleco/Anatel) e upsell incremental (R\$29/mês, diferencial auditável entre ARPU Controle e Pré-Pago) sejam validadas operacionalmente. O plano de monitoramento em produção (seção 9) define os gatilhos e protocolos que garantem a detecção precoce de qualquer desvio dessas premissas antes que se traduzam em erosão de resultado.

A Claro possui, neste modelo, uma vantagem informacional genuína sobre qualquer bureau de mercado: o comportamento transacional de seus próprios clientes pré-pagos. O Behavior Score transforma essa vantagem em decisão de crédito precisa, ética e rentável - provando matematicamente que inclusão financeira responsável e lucratividade sustentável não são objetivos opostos.