

Plano de Execução

Hackathon PoD Academy • Modelo de Behavior (Pré → Controle)

1. Contexto de Negócio e Entendimento do Problema

Este documento detalha o desafio estratégico, os objetivos de negócio e o escopo técnico do projeto desenvolvido pelo Squad03 do Hackathon PoD Academy em parceria com a Claro, com foco na conversão sustentável de clientes da base Pré-paga para o Controle.

1.1 Contexto e Problema de Negócio

A Claro busca expandir a base de clientes em planos de forma sustentável, equilibrando crescimento e gestão de risco.

O Desafio: Identificar clientes pré-pagos com maior potencial de migração para o plano Controle e menor probabilidade de inadimplência, permitindo a priorização de ofertas, a redução de risco financeiro e aumento da rentabilidade operacional.

1.2 Objetivo do Projeto

Desenvolver um Modelo de Behavior (visão unificada por CPF/cliente) para estimar o risco de inadimplência no contexto de migração Pré → Controle, entregando:

- **Score Individual:** Risco estimado por cliente.
- **Faixas de Risco:** Divisão em decis/bins para suporte à decisão operacional.
- **Recomendação de Política Inicial:** Definição de cortes e análise de *trade-offs* entre risco vs massa de clientes.

1.3 Valor para o Negócio

- **Aumento de Faturamento:** Melhor direcionamento da oferta de migração para perfis com maior sustentabilidade e maior LTV (*Lifetime Value*) esperado.
- **Redução de Custos:** Mitigação da inadimplência e menor desperdício de recursos em campanhas para perfis de alto risco.
- **Eficiência Operacional:** Decisão padronizada, explicável e baseada em dados, reduzindo o retrabalho manual.

2. Abordagem da Solução: Técnicas, Ferramentas e Estratégias

Detalhamento da *stack* tecnológica e as metodologias aplicadas no projeto, justificando as escolhas baseadas no cenário de execução em uma VPS (*Virtual Private Server*) atuando como uma Prova de Conceito (PoC) de uma plataforma de dados moderna, ponta a ponta e escalável.

2.1 Stack Tecnológica e Justificativas

- **2.1.1 Infraestrutura e Orquestração**
 - **Docker & Docker Compose:** Base para o isolamento de serviços em containers. Garante que MinIO, Postgres e Airflow coexistam na VPS sem conflitos de dependências e com portabilidade garantida.
 - **Apache Airflow:** O "maestro" do projeto. Responsável pelo agendamento e monitoramento dos fluxos (DAGs), garantindo a ordem de execução desde a ingestão até a entrega dos modelos de ML.
- **2.1.2 Armazenamento e Data Lake (MinIO)**
 - **MinIO (S3-Compatible):** Implementa a Arquitetura Medallion (BRONZE, SILVER, GOLD) em um *storage* de objetos local. O diferencial é ser *Cloud-Ready*: o código escrito para o MinIO funciona nativamente no AWS S3 caso a PoC avance para nuvem pública.

- **2.1.3 Processamento e Qualidade**

- **DuckDB (Vectorized Query Engine):** O "coração" do processamento. Por ser uma *engine in-process*, ele não requer um cluster pesado (como Spark), sendo extremamente eficiente em ambientes de VPS com recursos limitados de memória e CPU. Oferece performance de nível Spark para arquivos Parquet e CSV com a volumetria do nosso cenário.
- **Python & Pandas:** Linguagem base para orquestração, automação de scripts de *profiling* e integração entre os componentes.
- **Pandera:** Utilizado para Contratos de Dados na Origem. Garante que o dado que entra na camada Landing/Raw respeite o *schema* esperado, evitando o "efeito cascata" de erros nas camadas posteriores.

- **2.1.4 Transformação e Data Warehouse (Arquitetura Bônus)**

- **dbt (Data Build Tool) & PostgreSQL:** O dbt gerencia o ciclo de vida do SQL no PostgreSQL, organizando a transformação em camadas lógicas: `raw_schema`, `dw_staging`, `dw_core` (Star Schema) e `dw_marts`. Garante documentação e testes automatizados.

- **2.1.5 Ciência de Dados e Entrega**

- **MLflow:** Gerencia o ciclo de vida dos modelos de Machine Learning (Produção `.pkl`), permitindo rastrear experimentos, parâmetros e versões dos modelos treinados.
- **Streamlit (Bônus):** Transforma os dados modelados em *Decision Intelligence*, entregando dashboards interativos e aplicações analíticas diretamente para os *stakeholders*.

2.2 Estratégias de Engenharia Aplicadas

A implementação atual está dimensionada com base nos dados amostrais. No entanto, a arquitetura concebida considerando a volumetria real da Claro, com possibilidade de escalonamento vertical de recursos, independente do ambiente de hospedagem.

- **2.2.1 Escopo e Escalabilidade (Visão de Negócio)**

Esta abordagem foi adotada para:

- Garantir a viabilidade técnica dentro dos recursos da VPS.
- Manter a simplicidade e agilidade durante o ciclo de desenvolvimento.
- Validar a lógica de governança antes do *scale-up* para o ambiente produtivo final.

- **2.2.2 Arquitetura Medallion & Star Schema**

Organizamos o dado para dois propósitos distintos:

- **No Lake (MinIO):** Foco em armazenamento eficiente, imutabilidade e histórico transacional.
- **No DW (Postgres) (Bônus):** Modelagem dimensional (Fatos e Dimensões) otimizada para performance de BI e consumo por aplicações.

- **2.2.3 Estratégia de Particionamento & Run_ID**

Adotamos o particionamento físico por `ano_mes=YYYYMM` associado ao metadado técnico `run_id`.

Benefício: Permite o *Partition Pruning* no DuckDB (lê apenas o necessário) e isola execuções. Se um processo falha, o Airflow pode re-executar apenas aquela *run* específica sem afetar o histórico estável.

- **2.2.4 Política de Retenção Ativa**

Utilitário de limpeza programática que gerencia o ciclo de vida das *runs* no *storage*.

Por quê: Como o MLflow e as camadas do Data Lake geram alto volume de arquivos, a retenção automática evita que o armazenamento da VPS se esgote, mantendo a resiliência operacional.

2.3 Estratégia de Modelagem

- **2.3.1 Princípios de Solução**

- **Granularidade Única:** Visão consolidada por CPF/Cliente.
- **Temporalidade Controlada:** *Features* calculadas em janela anterior ao target para evitar vazamento de dados (*leakage*).
- **Reprocessamento Consistente:** Capacidade de recalcular a ABT por data de referência quando necessário.
- **Auditabilidade:** Variáveis versionadas e documentadas em Books de Variáveis.

- **2.3.2 ABT (Analytical Base Table) - Contrato para Modelagem**

A ABT é construída a partir da camada Silver, agregando sinais por cliente com janelas temporais (ex: 30/60/90 dias). Domínios previstos (Mapeados à Silver):

- Atrasos/Delinquência.
- Pagamentos.
- Recargas.
- Uso Telco/Engajamento.
- Bureau Móvel (Score Externo).
- Cadastro/Estabilidade.

- **2.3.3 Definição do Target e Modelagem**

O Target (Inadimplência) será formalizado no início da execução (Sprint 0), contemplando a definição operacional do evento, janela de performance (horizonte para observação), data de referência para *features* e corte temporal para validação.

- **Modelagem:** Inicia com um Baseline rápido e reproduzível para estabelecer referência, evoluindo de forma incremental via *Feature Engineering* e validação temporal.

- **Entrega Operacional:** Disponibilização de score contínuo, faixas/decis com taxa de inadimplência por faixa e sugestão de política de corte (*trade-off* risco vs massa).

2.4 Diferencial da Solução e Escalabilidade

A arquitetura provada nesta PoC integra o que há de melhor no ecossistema de dados moderno. Embora rode hoje em uma VPS, a separação clara entre Storage (MinIO), Compute (DuckDB) e Modelagem (dbt) permite que a solução escale horizontalmente para nuvens com esforço de migração próximo de zero, validando a viabilidade técnica e de governança do projeto.

3. Plano de Trabalho: Divisão de Tarefas e Responsabilidades

Detalhamento da metodologia de gestão do projeto e a distribuição de responsabilidades entre os membros da Squad, visando garantir agilidade, governança e entregas incrementais na Prova de Conceito (PoC).

3.1 Agilidade e Planejamento

- **Metodologia Híbrida:** O planejamento do projeto foi estruturado combinando as boas práticas do PMBOK (garantindo governança, controle de escopo, riscos e custos) com Metodologias Ágeis, priorizando entregas incrementais e adaptação contínua. Esta abordagem permite o controle rigoroso de prazos e recursos em paralelo com a flexibilidade para pivotar estratégias de processamento conforme a análise dos dados.
- **Gestão do Fluxo (Kanban):** A gestão das atividades é realizada por meio de quadros Kanban no GitHub Projects, integrando planejamento, execução e versionamento em um único ecossistema. Para garantir a especialização técnica e a fluidez das entregas, dividimos a gestão em dois projetos distintos:

- **Data & Analytics - Squad 3:** Focado no ciclo de vida da ciência de dados e modelos de ML.
- **Data Engineering - Squad 3:** Focado na infraestrutura de processamento, orquestração e sustentação do Data Lake.

O uso desses quadros possibilita:

- Controle visual detalhado das tarefas (To Do, In Progress, Done).
- Monitoramento preciso de Milestones do Projeto, como a finalização de camadas específicas ou deploy de modelos.
- Identificação de dependências críticas entre engenharia e analytics.

3.2 Organização da Squad e Responsabilidades

A equipe é composta por 10 especialistas, organizados em frentes de trabalho com entregáveis claros para as bancas de qualificação.

Engenharia de Dados (Data Engineering)

- **Foco:** Construção e manutenção da infraestrutura de dados.
- **Responsabilidades:**
 - Estruturar e manter a arquitetura de dados do projeto.
 - Implementar e versionar pipelines de ingestão, transformação e saneamento de dados.
 - Garantir qualidade, consistência e governança dos dados nas camadas Raw, Bronze, Silver e Gold.
 - Implementar *profiling*, validações e observabilidade dos dados.
 - Assegurar reprocessabilidade e rastreabilidade das execuções.
 - Definir e manter contratos de dados entre domínios e camadas.
 - Suportar a construção da **ABT (Analytical Base Table)** e a camada de consumo para modelagem.

- **Entregáveis:**
 - Stack de dados executável em ambiente containerizado.
 - Pipelines versionados para ingestão e transformação de dados.
 - Evidências de *profiling* e qualidade de dados.
 - Contratos de dados e *lineage* documentados.
 - Documentação técnica da arquitetura e dos pipelines.
- **Responsáveis:** Fred (Líder), Rafael e Ronaldo (Apoio).

Ciência de Dados (Data Science)

- **Foco:** Inteligência de dados e modelagem preditiva.
- **Responsabilidades:**
 - Definição formal do target, janelas (feature/performance) e validação temporal.
 - Especificação e construção da **ABT (Analytical Base Table)**.
 - Baseline e evolução até o modelo final (.pkl) com pipeline reproduzível.
 - Tradução de métricas em decisão operacional (faixas, corte e simulações).
 - Plano de monitoramento (performance, drift e gatilhos de *retraining*).
- **Entregáveis:**
 - Modelo Baseline (Banca de Qualificação).
 - Modelo Final .pkl (Banca Final).
 - Plano de Monitoramento (Banca Final).
- **Responsáveis:** Lucas (Líder), Gabriel e Gustavo Lazzarotto (Apoio).

Análise de Dados (Analytics)

- **Foco:** Tradução de dados em insights de negócio e Storytelling.
- **Responsabilidades:**
 - Estudo de Público-Alvo: perfil, segmentações, qualidade, outliers e vieses.
 - Definição das métricas de sucesso (técnicas e de negócio).
 - Liderança dos Books de Variáveis (significado, regra e interpretação).
 - *Storytelling* e consolidação de impacto com insights acionáveis por faixa.
- **Entregáveis:**
 - Estudo de Público-Alvo (Banca de Qualificação).
 - Books de Variáveis (Coautoria).
 - Seções do Plano: entendimento do problema, métricas, riscos e governança.
- **Responsáveis:** Carlos Augusto (Líder), Daniel e Gabriel (Apoio).

Documentação e Governança

- **Foco:** Manutenção do conhecimento, conformidade técnica e narrativa.
- **Responsabilidades:**
 - Mapeamento de *Lineage* e documentação técnica (*Profiling*/Dicionário).
 - Garantia da aplicação das políticas de governança via código.
 - Padronização de narrativa e consistência dos materiais para as bancas.
- **Interfaces Críticas:** Apoio na redação técnica e consistência entre o que é processado e o que é documentado.
- **Responsáveis:** Gustavo Torelli (Líder), Michele e Gustavo Lazzarotto (Apoio).

3.3 Interfaces e Dependências

Para o sucesso da PoC, estabelecemos protocolos de colaboração entre as frentes:

- **Engenharia ↔ Documentação:** Sincronização técnica para o mapeamento de metadados, linhagem e políticas de governança. A Engenharia produz sua própria documentação garantindo que a documentação central reflita com precisão o que foi implementado via código.
- **Engenharia ↔ Science/Analytics:** Alinhamento sobre janelas temporais e regras de reprocessamento para garantir que a ABT (Analytical Base Table) reflita a realidade dos dados na camada Silver.
- **Science ↔ Documentação:** Padronização das métricas e lógicas de variáveis nos Books de Variáveis para garantir a auditabilidade dos experimentos e resultados.
- **Analytics ↔ Squad:** Consolidação dos resultados técnicos em uma *storyline* executiva e visual para a apresentação final estratégica.

4. Cronograma e Planejamento de Entregas

Detalhamento dos marcos oficiais, o planejamento tático da Sprint 0 e a estratégia de mitigação de riscos para garantir o sucesso da PoC no Hackathon Claro.

4.1 Marcos Oficiais do Projeto

- **14/01/2026:** Entrega do Plano de Execução.
- **15/01/2026:** Checkpoint: Ciência de Dados.
- **20/01/2026:** Checkpoint: Engenharia de Dados.
- **03/02/2026:** Banca de Qualificação.
- **05/03/2026:** Banca Final.

4.2 Sprint 0 - Planejamento Imediato (Até 14/01)

Foco em travar escopo, decisões-base e consolidação do Plano de Execução.

- **D0 (11/01):** Analytics define métricas de sucesso, estrutura do Estudo de Público-Alvo e checklist de qualidade nas Silvers. DS define target, granularidade e desenho da ABT. Saída: *1-Page* com objetivos e entregáveis.
- **D1 (12/01):** Analytics entrega relatório de qualidade/cobertura. DS define estratégia de validação (split temporal) e features. Saída: Seções de abordagem, métricas e riscos preenchidas.
- **D2 (13/01):** Analytics cria backlog com épicos. DS prioriza features e critérios de aceite. Saída: Versão *Review* do Plano.
- **D3 (14/01):** Consolidação final de todas as frentes. Saída: Entrega Formal do Plano finalizado.

4.3 Evolução das Entregas

- **4.3.1 Até a Qualificação (15/01 → 03/02)**
 - **15/01:** Aprovação de Target/ABT + Baseline encaminhado + Primeiros insights de EDA.
 - **20/01:** Validação do contrato Silver → ABT e definição da estratégia de reprocessamento.
 - **03/02:** Entrega Final da Fase: Estudo de Público-Alvo + Books + Baseline + Documentação inicial + Arquitetura.
- **4.3.2 Até a Banca Final (04/02 → 05/03)**
 - **Modelagem:** Modelo final (.pkl), faixas de risco e recomendação de política inicial.
 - **Observabilidade:** Plano de monitoramento completo.
 - **Engenharia:** Documentação técnica consolidada e Storyline da apresentação final.

4.4 Governança e Cerimônias

- **Daily:** Reuniões curtas (10–15 min) para alinhamento de impedimentos.
- **Checkpoint Interno:** 2x por semana para validação de evidências (EDA, ABT, Modelagem, Books).
- **Revisão Pré-Banca:** Checklist de consistência entre premissas, números e narrativa.

4.5 Escopo e Entregáveis

- **Em escopo (Mínimo para Bancas):** Plano de Execução, Estudo de Público-Alvo, Books de Variáveis, Modelo Baseline, Modelo Final (.pkl), Plano de Monitoramento, Documentação de Engenharia e Apresentação Final.
- **Fora de escopo:** Ativação Produtiva em canais reais, Dados Externos (além da amostragem) e Implementação completa de MLOps.

4.6 Estado Atual do Projeto (Status em 14/01/2026)

O projeto encontra-se com a fundação de dados consolidada:

- **Infraestrutura:** Repositório versionado com *profiling* e EDA inicial.
- **Engenharia:** Ingestão via MinIO + DuckDB com suporte a S3.
- **Arquitetura Medallion:** Camadas Raw, Bronze e Silver estruturadas.
- **Domínios Processados:** Scripts Silver finalizados para os domínios de Atrasos, Pagamentos, Recargas, Telco, Score Bureau Móvel e Dados Cadastrais.

5. Riscos, Dependências e Estimativa de Custos

Esta seção apresenta a análise de risco integrados, as dependências críticas da arquitetura e a viabilidade financeira do projeto, utilizando as boas práticas do PMBOK aplicadas ao cenário de Prova de Conceito (PoC).

5.1 Matriz de Riscos Integrada (Engenharia & Ciência de Dados)

Escala adotada:

- **Probabilidade (P):** Baixa (1) | Média (2) | Alta (3)
- **Impacto (I):** Baixo (1) | Médio (2) | Alto (3)
- **Nível de Risco:** $P \times I$

ID	Risco	Categoria	P	I	Nível	Estratégia de Mitigação
R1	Esgotamento de armazenamento na VPS	Infra	3	3	9	Implementação da Política de Retenção Ativa e limpeza de <code>run_id</code> obsoletas.
R2	Dados inconsistentes ou ausentes na origem	Qualidade	3	2	6	Validações automatizadas com Pandera e monitoramento estatístico via Profiling .
R3	Concorrência de recursos (CPU/RAM) na VPS	Processamento	2	3	6	Limites de memória no DuckDB e escalonamento de tarefas via Airflow .
R4	Instabilidade ou indisponibilidade da fonte	Integração	2	3	6	Versionamento dos datasets (imutabilidade) para garantir a reprocessabilidade.
R5	Target Ambíguo	Modelagem	2	3	6	Definição formal registrada + validações por safra.
R6	Vazamento Temporal (<i>Leakage</i>)	Modelagem	2	3	6	Split temporal + features anteriores ao target + checklist DS obrigatório.
R7	Inconsistência de chaves/temporalidade	Engenharia	2	3	6	Testes de unicidade/cobertura + contrato explícito da ABT.
R8	Books pouco interpretáveis	Analytics	2	2	4	Cada variável/grupo com definição, janela, regra, interpretação e racional.
R9	Corrupção de arquivos em escrita interrompida	Persistência	1	3	3	Estratégia de escrita atômica e isolamento por <code>run_id</code> .
R10	Perda de metadados de experimentos (MLflow)	Modelagem	1	2	2	Backup periódico do volume Docker onde residem os artefatos do MLflow.
R11	Mudanças de escopo ou ferramentas	Arquitetura	1	2	2	Uso de padrões abertos (S3/Parquet), stack desacoplada e versionamento via Git.

5.2 Justificativa de Mitigação

A estratégia central baseia-se no tripé:

- **Imutabilidade e Idempotência:** O uso de `run_id` garante que dados antigos nunca sejam corrompidos por processos novos que falharam, permitindo re-execuções sem duplicidade.

- **Rigor de Modelagem:** O controle rigoroso das janelas de observação e performance (R6) associado a contratos explícitos de ABT (R7) evita o desperdício de esforço em modelos sem validade estatística.
- **Observabilidade:** O monitoramento via Profiling e logs do Airflow permite agir proativamente antes que limites físicos das VPS ou anomalias de dados interrompam a operação.

5.3 Estimativa de Custos (Fase PoC)

O projeto foca em Custo Zero de Licenciamento, utilizando exclusivamente ferramentas Open Source.

- **5.3.1 Custos de Infraestrutura e Software**

Recurso	Tipo	Custo Mensal Estimado
VPS (Ambiente Docker)	Hospedagem	~ R\$ 100,00
DuckDB, PostgreSQL, Airflow, dbt	Licença	R\$ 0,00
MinIO, MLflow, Streamlit	Licença	R\$ 0,00
Total Estimado		**~ R\$ 100,00 / mês**

- **5.3.2 Recursos Humanos (Squad de Dados)**

A PoC foi executada por uma Squad multidisciplinar de 10 especialistas, operando em regime de dedicação exclusiva durante as Sprints do projeto.

5.4 Estimativa de Custos (Fase PoC)

A escolha do DuckDB como motor vetorial in-process é o principal fator de mitigação de custos e riscos de performance. Ele permite processar volumes de dados de nível Spark sem a necessidade de instâncias de alto custo (High-Memory), tornando a PoC viável em uma VPS modesta.

5.5 Justificativa Técnica de Eficiência

O uso do DuckDB como motor vetorial *in-process* permite processar volumes altos sem clusters caros. A arquitetura é elástica, permitindo migração para nuvens públicas ou *upscale* de hardware sem refatoração.

A arquitetura foi desenhada para ser altamente elástica:

- **Escalabilidade de Software:** Os componentes são modulares e podem ser movidos para nuvens públicas sem refatoração de código.
- **Escalabilidade de Hardware:** Permite Upscale direto de CPU/RAM na VPS, estendendo a vida útil da PoC conforme o crescimento da volumetria ou complexidade dos modelos de ML.

6. Métricas de Sucesso e Avaliação

Definição dos indicadores técnico e de negócio utilizados para validar a eficácia do modelo de propensão e a saúde operacional da plataforma de dados.

6.1 Métricas Técnicas (Model Performance)

Para garantir a capacidade preditiva e a estabilidade do modelo de Inadimplência, monitoramos:

- **Poder Discriminante:** ROC-AUC e KS/Gini para avaliar a separação entre “bons” e “maus” pagadores.
- **Ordenação de Risco:** Lift por faixa, garantindo que as faixas de maior score concentrem a maior taxa de inadimplência.
- **Estabilidade:** Monitoramento por safra para validar se o comportamento do modelo se mantém consistente ao longo do tempo.

6.2 Métricas de Negócio (Business Impact)

Indicadores que traduzem a performance técnica em valor para a Claro:

- **Qualidade de Risco:** Inadimplência esperada por faixa de score.
- **Cobertura:** Percentual da massa elegível (clientes pré-pagos) mapeado pelo modelo.
- **Eficiência de Política:** Simulações de política de corte (ex.: análise de impacto ao aprovar o Top X% de menor risco).

6.3 Métricas de Plataforma (Data Health)

Métricas geradas como subproduto da arquitetura de engenharia, governança e observabilidade.

- **Observabilidade:** Monitoramento de *Freshness (atualização)*, Volume e *Schema Drift*.
- **Qualidade:** Integridade técnica (tipagem forte) e semântica via Pander.
- **Resiliência:** Disponibilidade de estados anteriores via Versionamento de Execuções (`run_id`).
- **Eficiência de Custos:** Gestão do *storage* na VPS via Política de Retenção.
- **Rastreabilidade:** Integridade da jornada do dado entre as camadas Medallion (Data Lineage).